

Chapitre 3

Statistique descriptive

La statistique descriptive est un ensemble des méthodes permettant à décrire, traiter et interpréter des ensembles des données. Cette description des données se fait à travers deux approches : graphique et numérique. Dans ces deux approches, aucune hypothèse probabiliste n'est faite sur les données considérées, il n'est pas nécessaire de supposer que les données observées proviennent par exemple d'une loi de probabilité.

3.1 Définitions de base

L'ensemble étudié est appelé **population**. Les éléments de la population sont appelés **individus** ou **unités statistiques**. La population est étudiée selon un ou plusieurs **variables statistiques** ou **caractères statistiques**.

Échantillon est un sous-ensemble de la population dont les individus feront l'objet de l'étude. Le choix de l'échantillon se fait en respectant certaines règles (théorie des sondages).

La valeur prise par la variable sur un individu est appelée **modalité** ou **observation**. Les **Données** sont constituées par l'ensemble des modalités (série statistique, tableaux, fichiers, données primaires).

3.2 Types de variables statistiques

On distingue deux sortes de variables ou caractères :

- Les variables quantitatives ;
- Les variables qualitatives

3.2.1 Variable qualitative

La variable est dite qualitative quand les modalités sont des catégories.

- **Variable qualitative nominale** : La variable est dite qualitative nominale quand les modalités ne peuvent pas être ordonnées. Exemple : Nationalité, Sexe, Couleur, Groupes sanguins, etc

- **Variable qualitative ordinale** : La variable est dite qualitative ordinale quand les modalités peuvent être ordonnées. Exemple : Mention à un examen, Catégorie socioprofessionnelle de modalités : "ouvriers", "employés", "cadres", etc.

3.2.2 Variable quantitative

Une variable est dite quantitative si toutes ses modalités sont numériques.

- **Variable quantitative discrète** : Une variable est dite discrète, si l'ensemble des modalités est discret (valeurs isolées). Exemple : Nombre d'enfants par famille, le nombre d'accidents, etc.
- **Variable quantitative continue** : Une variable est dite continue, si l'ensemble des modalités est continu. Exemple : le poids, la taille, la température, le taux de glycémie, le rendement, etc.

3.3 Distributions statistiques : Effectifs, fréquences

Lorsque le recueil des données a été effectué, on associe, à chaque modalité prise par le caractère étudié, son **effectif** ou **fréquence absolue** (nombre d'apparitions de cette modalité dans les données). Pour les variables continues, les modalités sont des classes ou des intervalles.

Notation : les variables seront notées par des lettres majuscules $X, Y, Z, \dots$; on note leurs modalités par des lettres minuscules $x_i, y_j, z_l, \dots$ et les effectifs associés par $n_i, n_j, n_l, \dots$.

Exemple : X = sexe, x_1 = féminin, x_2 = masculin, n_1 = nombre de femmes, n_2 = nombre d'hommes.

Pour les variables continues, on commence par ranger les observations en classes, celles-ci étant des intervalles de la forme $[a_{i-1}, a_i[$. Ensuite, pour chaque classe, on compte le nombre d'individus dont le caractère appartient à la classe : ce nombre est l'**effectif de la classe**. On note k le nombre de classes.

La répartition en classes des données nécessite de définir a priori le nombre de classes k et donc l'amplitude de chaque classe. En règle générale, on choisit au moins cinq classes de même amplitude. Cependant, il existe des formules qui nous permettent d'établir le nombre de classes pour une série statistique de N observations.

- La règle de Sturge : $k = 1 + (3.3 \log_{10}(N))$.
- La règle de Yule : $k = 2.5 \sqrt[4]{N}$.

L'amplitude de classe est donc $(x_{\max} - x_{\min})/k$, où $x_{\max}$ (resp. $x_{\min}$) désigne la plus grande (resp. la plus petite) modalité.

Définition : On appellera **distribution statistique des effectifs** de la variable X :

- l'ensemble des données (x_i, n_i) , $i = 1, \dots, k$ si X est une variable qualitative ou discrète,
- l'ensemble des données $([a_{i-1}, a_i[, n_i)$, $i = 1, \dots, k$ si X est une variable continue.

Définition : On appelle

- **Fréquence relative** (ou proportion), associée à la modalité x_i du caractère (resp. à la classe $[a_{i-1}, a_i[$), la valeur f_i définie par :

$$f_i = \frac{n_i}{N}. \text{ Elle s'exprime souvent en pourcentage.}$$

- **Effectif cumulé (Fréquence cumulée absolue)**, associée à la modalité x_i du caractère (resp. à la classe $[a_{i-1}, a_i[$), le nombre N_i d'individus dont le caractère est inférieur ou égal à x_i :

$$N_i = \sum_{j=1}^i n_j.$$

- **Fréquence cumulée relative**, associée à la modalité x_i du caractère (resp. à la classe $[a_{i-1}, a_i[$), la valeur F_i définie par :

$$F_i = \sum_{j=1}^i f_j. \text{ Elle s'exprime souvent en pourcentage.}$$

Les résultats sont généralement présentés sous la forme des tableaux suivants.

Mod	Eff.(n_i)	Fré. rela.(f_i)	Eff. cumulées(Φ_i)	Fré. rela. cumulées(F_i)
x_1	n_1	f_1	n_1	f_1
x_2	n_2	f_2	$n_1 + n_2$	$f_1 + f_2$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_i	n_i	f_i	$\Phi_i = n_1 + n_2 + \dots + n_i$	$F_i = f_1 + f_2 + \dots + f_i$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_k	n_k	f_k	$\Phi_k = n_1 + \dots + n_k = N$	$F_k = f_1 + \dots + f_k = 100\%$
Total	N	100%		

TABLE 3.1 – Tableau de distribution de fréquences pour une variable qualitative ou discrète

Classes	Amplitudes	n_i	f_i	F_i	Densités
$[a_0, a_1[$	A_1	n_1	f_1	f_1	h_1
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$[a_{i-1}, a_i[$	$A_i = a_i - a_{i-1}$	n_i	f_i	$f_1 + \dots + f_i$	$h_i = \frac{f_i}{A_i}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$[a_{k-1}, a_k[$	A_k	n_k	f_k	100%	h_k
Total		N	100%		

TABLE 3.2 – Tableau de distribution de fréquences pour une variable continue

Exemple 3.1 On s'intéresse à la variable "taux de réussite au baccalauréat en 2015 dans l'académie de Kénitra" notée X et à la série statistique des valeurs prises par X sur 4 type de baccalauréat. Les données sont résumées dans le tableau suivant

x_i	n_i	f_i	F_i
Bac lettre	19 772	42,56%	42,56%
Bac éco	9 043	19,47%	62,03%
Bac science	13 439	28,93%	90,96%
Bac pro	4 200	9,04%	100,00%
Total	$N = 46454$	100%	

Exemple 3.2 (Défauts relevés sur une pièce électronique) Un fabricant de pièces électronique essaie une nouvelle machine; il compte le nombre de défauts sur 75 échantillons. Il a trouvé les résultats suivants :

TABLE 3.3 – Étude statistique du nombre de défauts sur une pièce : Tableau de distribution.

Nombre de défauts	n_i	$f_i(\%)$	N_i	$F_i(\%)$
0	38	50,6	38	50,6
1	15	20	$53 = 38 + 15$	70,6
2	11	14,7	$64 = 53 + 11$	85,3
3	6	8	$70 = 64 + 6$	93,3
4	3	4	$73 = 70 + 3$	97,3
5	2	2,7	$75 = 73 + 2$	100%
Total	$N = 75$	100%		

Exemple 3.3 On a relevé l'âge de 150 personnes. Les résultats de l'enquête sont donnés dans le tableau suivant :

Classes	Effectifs
[20, 25[	9
[25, 30[	27
[30, 35[	36
[35, 40[	45
[40, 50[	27
[50, 60[	6
N	150

3.4 Représentations graphiques d'une série de données


Très souvent, on préfère des représentations graphiques à des tableaux. Les graphes apparaissent comme plus "parlants". Ces représentations sont adaptées au type de variable étudiée : nominale, ordinale, discrète ou continue.

3.4.1 Variables nominales

Diagramme en bâtons

À chaque modalité, on associe un "bâton" de longueur proportionnelle à la fréquence f_i (ou, si l'on veut à l'effectif n_i).

FIGURE 3.1 – Diagramme en bâtons de fréquences pour l'exemple 3.1.




Pour une variable nominale, seules les hauteurs sont significatives ; l'ordre et l'écart des x_i ne sont pas significatifs.

Diagramme en secteurs

C'est la représentation la plus utilisée pour les variables nominales. L'angle de chaque secteur α_i est proportionnel à la fréquence f_i . En degré, on a $\alpha_i = 360 \times f_i$.

FIGURE 3.2 – Diagramme en secteurs de fréquences.

Type	n_i	f_i	α_i
Bac lettre	19 772	42,56%	153,23
Bac éco	9 043	19,47%	70,08
Bac science	13 439	28,93%	104,15
Bac pro	4 200	9,04%	32,55
Total	46 454	100%	360




3.4.2 Variables ordinales

On utilise les mêmes représentations que pour les variables nominales. Toutefois, il convient de noter que, pour le diagramme en bâtons, l'ordre des modalités a un sens concret, car il doit correspondre à l'ordre existant entre les valeurs.

3.4.3 Variables discrètes

Pour ce type de variables, on préfère le diagramme en bâtons car, dans ce cas, l'ordre et l'écart entre les bâtons sont significatifs.

FIGURE 3.3 – Diagramme en bâtons des effectifs pour l'exemple 3.2.



3.4.4 Variables continues

Histogramme

Pour représenter graphiquement la distribution statistique d'une variable continue, on a recours à un **histogramme**, qui est la juxtaposition de rectangles dont les bases sont les **amplitudes** des classes considérées $A_i = a_i - a_{i-1}$ et dont les hauteurs sont les quantités $h_i = \frac{f_i}{A_i}$ appelées **densités de fréquence**. L'aire du $i^{\text{ème}}$ rectangle vaut f_i . Si les amplitudes des classes sont égales, on peut prendre les hauteurs $h_i = f_i$. À partir de l'histogramme d'une variable statistique continue, on peut tracer le **polygone des fréquences** associé en procédant de la manière suivante :

- on joint par des morceaux de droites les milieux des segments horizontaux supérieurs des rectangles de l'histogramme ;
- on ajoute à droite et à gauche de l'histogramme des classes fictives, toutes deux de même amplitude et d'effectif nul, ce qui donne alors lieu à deux nouveaux segments. Voir la figure 3.4.





FIGURE 3.4 – Histogramme

Remarque 3.5 On ne doit pas "lisser" la courbe.

Exemple 3.4 On reprend l'exemple 3.3.

TABLE 3.4 – Tableau de distribution de la variable Âge.

Classes	n_i	A_i	f_i	F_i	h_i
[20, 25[	9	5	0,06	0,06	0,012
[25, 30[	27	5	0,18	0,24	0,036
[30, 35[	36	5	0,24	0,48	0,048
[35, 40[	45	5	0,3	0,78	0,06
[40, 50[	27	10	0,18	0,96	0,018
[50, 60[	6	10	0,04	1	0,004
N	150		1		



3.6 Fonction de répartition

Définition : La **fonction de répartition** du caractère quantitatif X est la fonction F , allant de l'ensemble des réels vers $[0, 1]$, définie par :

$$F(x) = \text{proportion d'individus de l'échantillon dont la valeur de } X \text{ est } \leq x.$$

Proposition 3.5 Si X est une variable quantitative discrète. Alors

$$F(x) = \begin{cases} 0 & \text{si } x < x_1 \\ F_{i-1} & \text{si } x_{i-1} \leq x < x_i, i \geq 2 \\ 1 & \text{si } x \geq x_k. \end{cases}$$

Dans la pratique, on ne l'utilisera que pour des variables continues. Pour ces dernières, la détermination de la fonction de répartition se fait de la manière suivante :

Soit X une variable continue, dont les valeurs sont rangées en classes $[a_0, a_1[, \dots, [a_{k-1}, a_k[$, avec des fréquences $f_1, \dots, f_k$.

— On commence par calculer les valeurs de F aux points du découpage

$$F(a_0) = 0, F(a_1) = F_1 = f_1, F(a_i) = F_i, F(a_k) = F_k = 1.$$

— Ensuite, dans chaque classe, on fait une interpolation linéaire (on relie les points extrêmes par un segment de droite).

— Puis on prolonge la courbe par 0 à gauche de a_0 et par 1 à droite de a_k (figure 3.5).




FIGURE 3.5 – Fonction de répartition.

Proposition 3.6 Si X est une variable quantitative continue. Alors, d'après la méthode d'interpolation linéaire, on obtient

$$F(x) = \begin{cases} 0 & \text{si } x < a_0 \\ F_{i-1} + \frac{f_i}{A_i}(x - a_{i-1}) & \text{si } a_{i-1} \leq x < a_i, i \geq 1 \\ 1 & \text{si } x \geq a_k. \end{cases}$$

Exercice 24 On reprend l'exemple du tableau 3.4. Tracer la fonction de répartition et calculer le pourcentage des personnes dont l'âge est supérieur ou égal 45.

3.7 Paramètres associés à la distribution d'une série de données

Le but de cette partie est donc de définir, pour chaque type de variable statistique, un certain nombre de caractéristiques (ou indicateurs), c'est-à-dire quelques nombres permettant de résumer de manière quantitative (et non plus qualitative) chaque distribution. Bien entendu, n'importe quelle quantité ne peut pas être un indicateur.

On se limitera ici à 2 types de caractéristiques statistiques :

- celles dites de **tendance centrale**, qui donnent un " ordre de grandeur " de la variable étudiée en dégagant la modalité de la variable la plus représentative ;
- celles dites de **dispersion** qui, elles, fournissent des informations sur la façon dont les individus se répartissent (se dispersent) autour de la tendance centrale.

Le tableau 3.5 suivant donne les caractéristiques étudiées pour chaque type de variable.

Type de la variable	Tendance centrale	Dispersion
Nominale	Mode	
Ordinale	Mode, médiane, quantiles	Écart interquartile
Quantitative	Mode, médiane, quantiles, moyenne	Écart-type, écart interquartile

TABLE 3.5 – Caractéristiques d'une distribution.

3.7.1 Paramètres de tendance centrale

Mode

Il est défini pour tous les types de variables. Le mode n'est pas nécessairement unique.

Définition :

- si X est une variable statistique nominale, ordinale ou discrète, le **mode** de la distribution associée est la modalité de X la plus représentée, c'est-à-dire celle pour laquelle l'effectif est le plus grand ;
- si X est une variable continue, la **classe modale** de la distribution associée est la classe dont la densité de fréquences est la plus élevée. Si $[a_{i-1}, a_i[$ est la classe modale, on peut alors approximer le mode par la méthode des diagonales (voir la figure 3.6) :

$$\frac{Mo - a_{i-1}}{a_i - a_{i-1}} = \frac{h_i - h_{i-1}}{(h_i - h_{i-1}) + (h_i - h_{i+1})} = \frac{\Delta_1}{\Delta_1 + \Delta_2} \Rightarrow Mo = a_{i-1} + A_i \frac{\Delta_1}{\Delta_1 + \Delta_2}.$$




FIGURE 3.6 – Méthode des diagonales

Remarque 3.8 Une distribution est dite **unimodale** si elle admet un mode unique, **bimodale** si elle admet deux modes ou **multiimodale** si elle admet plusieurs modes.

Exemple 3.7 Le mode dans la table 3.1 est la modalité "bac lettre". Sur la table 3.4, la classe modale est $[35, 40[$, donc $Mo = a_{i-1} + A_i \frac{\Delta_1}{\Delta_1 + \Delta_2} = 35 + 5 \times \frac{0,06 - 0,048}{0,06 - 0,048 + 0,06 - 0,018} \approx 35,63$.

Médiane

Définition : La **médiane** est la valeur "centrale" de la série. On dit qu'elle partage la série en deux moitiés. Ainsi 50% des éléments de l'échantillon ont une valeur inférieure à la médiane et 50% une valeur supérieure.

En général, on note $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(i)} \leq \dots \leq x_{(N)}$ la série ordonnée par ordre croissant de la série brute $x_1, x_2, \dots, x_i, \dots, x_N$ de données. Alors,

$$\begin{aligned} \text{Si } N \text{ est impair} & \quad Mé = x_{(\frac{N+1}{2})} \\ \text{Si } N \text{ est pair} & \quad Mé = \frac{1}{2} \left\{ x_{(\frac{N}{2})} + x_{(\frac{N}{2}+1)} \right\} \end{aligned}$$

Exemple 3.8 Trouver la médiane de la série brute suivante : 21, 25, 28, 30, 27, 24, 31, 21, 28, 30, 25, 28, 26, 25.

Réponses : Ordonnons la série par ordre croissant : 21, 21, 24, 25, 25, 25, 26, 27, 28, 28, 28, 30, 30, 31. On a $N = 14$, pair, donc la médiane est $\frac{x_{(7)} + x_{(8)}}{2} = \frac{26 + 27}{2} = 26,5$.

Définition : La **médiane** de la distribution d'une variable continue X , répartie en classes $([a_{i-1}, a_i])_{1 \leq i \leq k}$ est donnée par :

— si $F(a_{i-1}) \leq 0,5 < F(a_i)$, la **classe médiane** est $[a_{i-1}, a_i[$ et on calcule la médiane par interpolation linéaire sur l'intervalle $[a_{i-1}, a_i[$:

$$Mé = a_{i-1} + (a_i - a_{i-1}) \frac{0,5 - F(a_{i-1})}{F(a_i) - F(a_{i-1})}$$

avec F fonction de répartition de X (Proposition 3.6),

Exemple 3.9 Dans la table 3.4, la classe médiane est $[35, 40[$ car $F(35) = 0,48 < 0,5 < F(40) = 0,78$. En appliquant la formule de la médiane, on obtient $Mé = 35,33$.

Remarque 3.9 la médiane est peu sensible aux valeurs extrêmes de la variable, donc aux erreurs de mesures qui, bien souvent, produisent des valeurs aberrantes. On dit que la médiane est **robuste** ou **résistante**.

Quantiles-Quartiles

La notion de médiane peut se généraliser à celle de quantile. Soit α dans l'intervalle $]0, 1[$. On note $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(i)} \leq \dots \leq x_{(N)}$ la série ordonnée par ordre croissant de la série brute $x_1, x_2, \dots, x_i, \dots, x_N$ de données. Alors on définit le nombre Q_α , quantile d'ordre α , par

$$\begin{aligned} \text{Si } N\alpha \text{ n'est pas un entier naturel} & \quad Q_\alpha = x_{([N\alpha]+1)} \\ \text{Si } N\alpha \text{ est un entier naturel} & \quad Q_\alpha = \frac{1}{2} \left\{ x_{(N\alpha)} + x_{(N\alpha+1)} \right\} \end{aligned}$$

où $[N\alpha]$ représente la partie entière de $N\alpha$.

Si la variable statistique X est répartie en classes $([a_{i-1}, a_i])_{1 \leq i \leq k}$, alors on cherche la classe $[a_{i-1}, a_i[$ telle que $F(a_{i-1}) \leq \alpha < F(a_i)$. D'après l'interpolation linéaire, on écrit

$$Q_\alpha = a_{i-1} + (a_i - a_{i-1}) \frac{\alpha - F(a_{i-1})}{F(a_i) - F(a_{i-1})}.$$

Les cas particuliers les plus utilisés sont :

- les **quartiles**(partagent la série en 4) :
 - $Q_{0,25}$ **premier quartile** ;
 - $Q_{0,5}$ **médiane** ;
 - $Q_{0,75}$ **dernier quartile**.
- les **déciles**(partagent la série en 10) : $(Q_{0,1}, Q_{0,2}, \dots, Q_{0,9})$

Exemple 3.10 On reprend la série brute de l'exercice 3.8, Trouver les quartiles. Même question pour la table 3.4.

Réponses : Exercice 3.8 : on a $14 \times \frac{1}{4} = 3,5$ n'est pas entier, donc $Q_{0,25} = x_{(4)} = 25$ et $14 \times \frac{3}{4} = 11,5$ n'est pas entier, donc $Q_{0,75} = x_{(12)} = 30$. Table 3.4 : on obtient $Q_{0,25} = 30.2$ et $Q_{0,75} = 39.5$.

Moyenne arithmétique

La **moyenne** ne peut être définie que sur une variable quantitative.

Définition : La moyenne arithmétique d'une série de données $x_1, \dots, x_i, \dots, x_N$, ou tout simplement la moyenne, notée $\bar{X}$, est définie par :

$$\bar{X} = \frac{1}{N} \sum_{i=1}^N x_i = \frac{1}{N} \sum_{i=1}^k n_i x_i = \sum_{i=1}^k f_i x_i. \quad (3.1)$$

Pour obtenir une approximation de la moyenne d'une variable continue rangée en classes $[a_{i-1}, a_i[$, on remplace, dans les expressions en 3.1, les x_i par les centres des classes $c_i = \frac{a_{i-1} + a_i}{2}$.

Remarque 3.10

- la moyenne, prenant en compte toutes les valeurs observées, est très sensible aux observations extrêmes ou aberrantes ;
- Les courbes suivantes (Figure 3.7) donnent une idée sur la forme d'une distribution quelconque :




FIGURE 3.7 – Asymétrie d'une distribution

3.10.1 Paramètres de dispersion

L'idée étant de mesurer la dispersion de la distribution. Il y a trois manières de faire, qui correspondent à des buts différents.

- Sans référence à un indicateur de position, notion d'étendue.
- En référence à une valeur centrale (dispersion autour d'un indicateur de position), notion de variance.
- En indice relatif (coefficient de variation), dans un but de comparaison.

Étendue

L'**étendue**=observation maximale-valeur minimale= $x_{(N)} - x_{(1)}$.

Écart Interquartile

C'est la différence $IQ = Q_{0,75} - Q_{0,25}$. Cet intervalle englobe la moitié, ou approximativement la moitié, des observations qui se situent au centre de la distribution. Ce paramètre, est assez souvent utilisé et robuste.

Exemple 3.11 Soit la série des données suivante $S = \{3, 4, 5, 2, 1, 10, 16, 13, 7, 29, 21\}$, $Q_{0,75} = 14.5$ et $Q_{0,25} = 3.5$, $IQ = 14.5 - 3.5 = 11$.

Le diagramme en forme de boîte appelé **boîte à moustaches** ou **boxplot** en anglais est une bonne manière de représenter de manière visuelle la dispersion des données d'une distribution ainsi que sa symétrie ou asymétrie.




FIGURE 3.8 – Construction d'une boîte à moustaches.

Variance-Écart type

Définition : La **variance** d'une distribution de X , notée $Var(X)$, est la somme des carrés des écarts à la moyenne divisée par le nombre d'observations, c'est à dire :

$$Var(X) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{X})^2 = \frac{1}{N} \sum_{i=1}^k n_i (x_i - \bar{X})^2 = \sum_{i=1}^k f_i (x_i - \bar{X})^2.$$

Théorème 3.11 La variance peut aussi s'écrire

$$Var(X) = \overline{X^2} - \bar{X}^2 = \frac{1}{N} \sum_{i=1}^N x_i^2 - \bar{X}^2 = \frac{1}{N} \sum_{i=1}^k n_i x_i^2 - \bar{X}^2 = \sum_{i=1}^k f_i x_i^2 - \bar{X}^2.$$

Remarque 3.12 Pour le cas continu où c_i sont les centres des classes, on peut utiliser :

$$Var(X) \approx \frac{1}{N} \sum_{i=1}^N (c_i - \bar{X})^2 = \frac{1}{N} \sum_{i=1}^k n_i (c_i - \bar{X})^2 = \sum_{i=1}^k f_i (c_i - \bar{X})^2.$$

$$Var(X) \approx \frac{1}{N} \sum_{i=1}^N c_i^2 - \bar{X}^2 = \frac{1}{N} \sum_{i=1}^k n_i c_i^2 - \bar{X}^2 = \sum_{i=1}^k f_i c_i^2 - \bar{X}^2.$$

Pour des raisons d'unités et d'ordre de grandeur, on utilise l'**écart-type** : $\sigma(X) = \sqrt{Var(X)}$.

Exemple 3.12 Dans la table 3.4, $\bar{X} = 35,65$ et $Var(X) = 56,4525$.

Coefficient de variation

Dans certaines situations, on désire comparer le taux de dispersion de distributions alors que leur tendance de mesure respective ne sont pas comparables, l'objectif de ce coefficient est de fournir un indice quantitatif permettant cette comparaison et indépendant du choix des unités de mesure

$$C.V = \frac{\sigma(X)}{\bar{X}} \times 100 (\%).$$

Exemple 3.13 On considère deux classes de SMC dont les notes en Statistique du semestre 4 sont données par le tableau suivant :

Notes	5	6	7	8	9	10	11	12	13	14	15	16
Effectifs SMC_1	0	3	4	4	5	7	3	4	2	1	0	0
Effectifs SMC_2	2	4	3	3	3	4	3	2	2	3	1	2

On trouve que $\bar{X}_1 = 9,52$, $\bar{X}_2 = 9,94$, $\sigma_1 = 2,13$ et $\sigma_2 = 3,21$. Donc, $CV_1 = 22\%$ et $CV_2 = 32\%$. On en déduit que la 1ère classe est légèrement homogène que la deuxième.

3.13 Travaux dirigés

Exercice 1 Sachant que dans une université il y a deux fois plus d'étudiants en SVI qu'en SMC, quelles sont les fréquences manquantes (données fictives) :

SVI	SMA	STAPS	SMI	SMP	SMC	SI
?	0.05	0.22	0.15	0.20	?	0.14

Identifier la population, le caractère étudié et sa nature. Représenter graphiquement ces données.

Exercice 2 Un maraîcher est très fier de la quantité de fruits fournis par sa nouvelle sorte de cerisier. Pour tenter de comprendre quelle est la quantité "normale" de fruits pour un arbre de ce type, il mesure cette quantité sur chacun de ses 78 cerisiers et trouve les résultats suivants :

Quantité de cerises (Kg)	Nombre d'arbres	Quantité de cerises (Kg)	Nombre d'arbres
100	3	148	10
108	3	156	9
116	7	164	8
124	7	172	6
132	9	180	4
140	10	188	2

Faites deux histogrammes de ces valeurs ; le premier avec 12 classes (de 96 à 192), le second avec 6 classes. Que remarquez-vous et quelle conclusion pouvez-vous en tirer ?

Exercice 3 Au poste de péage, on compte le nombre de voitures se présentant sur une période de 5mn. Sur 100 observations de 5mn, on obtient les résultats suivants :

Nombre de voitures	1	2	3	4	5	6	7	8	9	10	11	12
Nombre d'observations	2	8	14	20	19	15	9	6	2	3	1	1

1. Construire la table des fréquences et le diagramme en bâtons en fréquences de la série du nombre de voitures.
2. Déterminer le mode, la médiane et les quartiles.
3. Calculer la moyenne et l'écart-type de cette série.
4. Étudier la symétrie de la série.

Exercice 4 On donne la série unidimensionnelle suivante, correspondant à la répartition des entreprises du secteur industriel en fonction de leur chiffre d'affaire en millions de dirhams.

Chiffres d'affaires	moins de 0,25	[0,25 ; 0,5[	[0,5 ; 1[	[1 ; 2,5[	[2,5 ; 5[	[5 ; 10[
Nombre d'entreprises	137	106	112	154	100	33

1. Construire l'histogramme des fréquences.
2. Construire le polygone des fréquences cumulées.
3. Calculer le mode, la médiane et la proportion d'entreprises dont le chiffre d'affaire est supérieur à 3 millions de dirhams.
4. Calculer le chiffre d'affaire moyen et l'écart-type de la série.

Exercice 5 Un fonctionnaire du Ministère des pêches a reçu les résultats de la pêche au homard en Mehdiya pour le printemps 2005. Le tableau qui suit nous indique le nombre de tonnes métriques de homards capturés par jour durant cette période.

Nombre de tonnes Métriques de homards	Nombre de jours
[0, 6[	9
[6, 8[	12
[8, 10[	30
[10, 12[	21
[12, 16[	9
[16, 20[	9

1. Définir pour ce problème la population et le caractère.
2. Calculer la moyenne et l'écart type du caractère.
3. Calculer la médiane du caractère.
4. Tracer l'histogramme et le polygone de fréquences du caractère.
5. Commenter l'écart entre la moyenne et la médiane du caractère.
6. Calculer la proportion de journées où les pêcheurs ont capturé un tonnage métrique de homards supérieur à 8.5 tonnes.
7. Un grossiste paie 70 000 Dhs la tonne métrique aux pêcheurs de homards. Par la suite, il vend le produit à des distributeurs au prix de 150 000 Dhs la tonne métrique. Toutefois, le grossiste doit payer des frais fixes de 500 000 Dhs par jour (transport, entreposage, main-d'oeuvre, administration).

- Si Y est le profit du grossiste par jour, exprimer Y en fonction du tonnage métrique de homards capturés.
- Calculer la moyenne et l'écart type du profit du grossiste par jour.